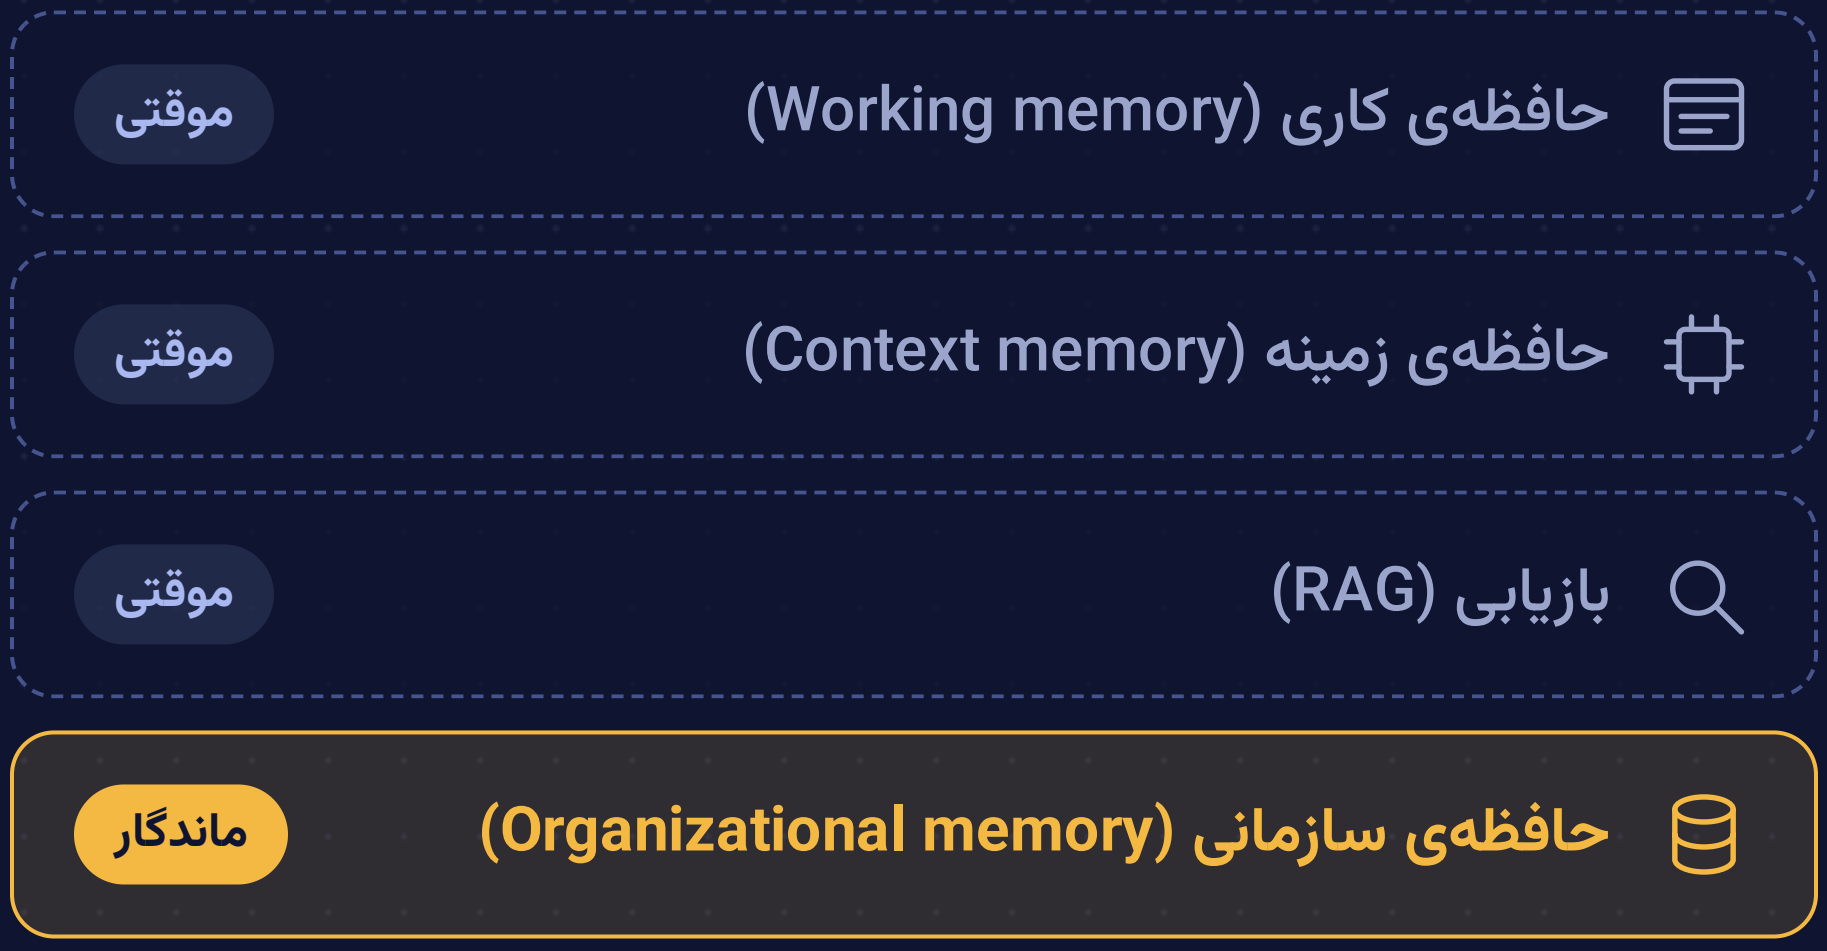
حافظه‌ی AI Agent واقعاً کجا زندگی می‌کنه؟

چهار لایه‌ی حافظه هست، و فقط یکی‌شون چیزی رو که agent یاد گرفته نگه می‌داره.



چرا agent هر دفعه انگار اولین باره که شما رو می‌بینه؟

اگه یک سؤال یکسان رو با فاصله‌ی دو هفته‌ای از agent بپرسید، ممکنه دفعه‌ی دوم جواب طوری باشه که انگار agent هیچ حافظه‌ای از دو هفته پیش نداره.



مشکل از مدل نیست، از زیرساخته: حافظه‌ی agent توی یک session، یک اپلیکیشن یا یک vector DB گیر افتاده.

سه لایه‌ی حافظه‌ی موقتی

حافظه‌ی کاری (Working memory)

همون context window توی یک مکالمه یا یک کار.

عمر — پایان session

حافظه‌ی زمینه (Context memory)

KV cache که سیستم استنتاجی (inference engine) حین یک session طولانی می‌سازه.

عمر — پایان همون اجرا

بازیابی (RAG)

اسناد مرتبط رو پیدا می‌کنه و به context میاره؛ نتیجه‌ی کار agent رو نگه نمی‌داره.

عمر — اسناد می‌مونن، نتیجه‌ها نه

لایه‌ی چهارم، همونی که کم داریم



بدون این نوع حافظه، agent می‌تونه یک داکیومنت رو عالی پیدا کنه، ولی نمی‌دونه هفته‌ی پیش بعد از خوندنش چه نتیجه‌ای گرفته.

نبودنش چه هزینه‌ای داره؟

هزینه‌ی token

هر session اسناد رو از نو می‌خونه و نتیجه‌ها رو دوباره درمیاره.

هزینه‌ی GPU

پردازش اولیه‌ی ورودی (prefill) برای contextی که قبلاً ساخته شده، دوباره انجام می‌شه.

دانش جمع نمی‌شه

هر agent حافظه‌ی جدای خودش رو داره و از کار بقیه استفاده نمی‌کنه.

افت کیفیت بی‌سروصدا

اصلاحات قبلی گم می‌شن و نتیجه‌های منسوخ برمی‌گردن.

چرا فقط vector DB کافی نیست؟

✓ Vector DB جواب می‌ده

کدوم سند مرتبطه؟

✗ جواب نمی‌ده

agent قبلاً چه تصمیمی گرفته؟

موقتی

معمولاً یک مجموعه‌ی ثابت از اسناد رو index می‌کنه؛ تصمیم‌ها و نتیجه‌های جدید agent بهش اضافه نمی‌شه.

جزیره‌ای

برای هر اپلیکیشن یک vector DB جدا، با امنیت و مدیریت جدا.

بدون حاکمیت داده (Governance)

برای سرعت جست‌وجو ساخته شده، نه برای کنترل دسترسی، سابقه‌ی دسترسی (audit) و سیاست نگهداری داده.

حافظه‌ی سازمانی چی لازم داره؟



پایدار

عمرش از session و حتی framework امروزتون بیشتر باشه.



اشتراکی

همه‌ی agentها هم بخونن، هم بهش اضافه کنن.



تحت حاکمیت داده

کنترل دسترسی، رمزنگاری و audit، مثل هر داده‌ی حساس دیگه.



فرمت باز

قفل فرمت اختصاصی یک framework نباشه.



سریع

تأخیر بازیابیش در حد یک سیستم تعاملی باشه.



خودکار پر بشه

حین کار agent ثبت بشه، نه با pipeline دستی.